모드 붕괴란? (GAN의 한계)

모드 붕괴(mode collapse)는 생성자에 서로 다른 노이즈를 넣어도 생성 결과가 일부 유형에 몰려, 실제 데이터 분포의 다양성을 충분히 재현하지 못하는 현상입니다.

모드 붕괴의 원인

GAN에서 모드 붕괴가 일어날 수 있는 중요한 이유는 **생성 이미지들 사이의 다양성을 직접 평가하거나 강제하는 장치가 기본 GAN에는 없기 때문**이다.

기본 GAN의 판별자는 여러 이미지를 배치로 입력받더라도, 보통 각 이미지에 대해 진짜일 점수를 따로 매긴다. 생성자는 이 점수로 계산한 손실을 역전파하여, 더 진짜처럼 평가받는 방향으로 가중치를 업데이트한다. 이때 **이미지들이 서로 지나치게 비슷하다는 이유만으로 별도의 벌점이 부과되지는 않는다.**

예를 들어 생성자가 서로 다른 노이즈로 거의 같은 모양의 숫자 3을 여러 장 만들었다고 하자. 판별자가 각각의 이미지를 진짜처럼 평가하면, 생성자의 손실은 작아진다. 생성 결과 전체의 다양성은 부족하지만, 현재의 학습 신호만으로는 그 문제를 충분히 교정하지 못할 수 있는 것이다. 그 결과 생성자는 노이즈의 차이를 충분히 활용하지 않고, 판별자를 잘 속이는 일부 출력에 집중할 수 있다.

또한 판별자와 생성자가 번갈아 업데이트되므로, 생성자는 계속 변하는 판별자의 평가에 맞춰 학습한다. 판별자가 반복되는 3을 알아차리면, 생성자가 다양한 숫자를 함께 표현하기보다 다른 일부 유형으로 몰리는 불안정한 상황도 생길 수 있다.

다만 **다양성에 대한 명시적인 벌점이 없다는 사실만으로 모드 붕괴가 반드시 발생하는 것은 아니다.** 판별자는 실제·생성 데이터의 분포 차이를 통해 다양성 부족을 간접적으로 학습할 수 있다. 문제는 실제 학습에서 그 신호가 충분하지 않거나 불안정할 수 있다는 점이다. 따라서 다양성을 직접 다루지 않는 구조는 모드 붕괴를 허용하는 중요한 요인이며, 여기에 생성자와 판별자의 학습 과정이 함께 작용한다고 설명할 수 있다.

GAN의 기본형을 가져간 후속 모델들의 연혁을 보자.

수많은 모델들이 있는데 좀 유의미한 결과가 있는 모델들만 추려보면 다음과 같다

안정화를 목표로 하거나 출력 이미지의 해상도를 높이는 등 여러 목적의 모델들이 존재

하나 이 중에서도 모드 붕괴에 초점을 두고 연구한 모델들을 살펴보자

unrolled-GAN, MAD-GAN, PacGAN, MSGAN 을 구체적으로 보자.

(개인적으로 아이디어가 흥미로웠거나 모드 붕괴의 주 원인 해결에 집중한다고 생각했던 모델들을 선정했음)

네 가지 모델의 원리를 각각 설명하고 모드 붕괴를 개선하는 부분, 한계를 작성

주요 연구들:

Unrolled GAN — "판별자가 더 학습한 뒤에도 이 전략이 통할까?"

기본 GAN에서 생성자를 업데이트할 때는 **현재 판별자를 고정한 채**, 그 판별자가 높은 점수를 주는 방향으로 생성자를 바꿈.

그러면 현재 판별자의 빈틈을 이용하는 전략이 유리할 수 있음. 예를 들어 지금은 특정한 3 모양만 반복해도 통하지만, 판별자가 조금 더 학습하면 쉽게 들킬 것.

Unrolled GAN은 이를 고려하기 위해 **판별자가 앞으로 몇 단계 업데이트되는 과정을 임시로 계산함**

1. 현재 생성자와 판별자에서 출발한다.
2. 생성자를 기준으로 판별자를 임시로 k번 업데이트한다.
3. 그 판별자를 사용해 생성자의 손실을 계산한다.
4. **판별자가 업데이트되는 과정까지 미분에 반영하여** 생성자를 업데이트한다.

판별자를 여러 번 학습시키는 단순한 방식과 무엇이 다른가?

판별자를 여러 번 학습하는 일반적인 방식	Unrolled GAN
더 학습된 판별자를 고정하고 생성자를 업데이트	생성자가 달라지면 판별자의 학습 결과도 어떻게 달라질지까지 반영

직관적으로 생성자는 **"이 출력을 만들면 지금은 통하지만, 판별자가 금방 적응하겠구나"**라는 영향을 학습 신호로 받는 것. 임시로 펼친 판별자 업데이트를 그대로 실제 판

별자의 최종 상태로 채택하는 것은 아님.

개선하는 부분: 현재 판별자에만 맞춰 일부 출력으로 몰리는 근시안적인 학습. 논문은 모드 커버리지와 다양성 개선을 보고했음.

한계: 업데이트 과정을 펼치고 미분하므로 계산·메모리 부담이 커지고, 제한된 단계만 고려하므로 먼 미래나 완전한 해결을 보장하지는 않음.

MAD-GAN — "생성자 여러 개가 다른 부분을 담당하면 어떨까?"

기본 GAN은 생성자 하나가 전체 데이터의 다양성을 표현해야 함. MAD-GAN은 **여러 생성자와 하나의 판별자**를 사용함.

그런데 생성자 수만 늘리면 모두 비슷한 이미지를 만들 수도 있잖아? 그래서 판별자의 역할도 바꾼다는 것

생성자가 3개라면 판별자는 입력을 다음 네 가지 출처로 구분함

판별자의 출력 범주	의미
실제	실제 데이터셋에서 온 이미지
생성자 1	G_1이 만든 이미지
생성자 2	G_2가 만든 이미지
생성자 3	G_3이 만든 이미지

생성자들은 실제로 평가받으려 하고, 판별자는 가짜 이미지의 출처까지 학습. 이 상호작용을 통해 **생성자들이 서로 구별되는 모드를 표현하도록 유도**하는 것이 핵심임.

개선하는 부분: 생성 모델 전체가 다양한 모드를 커버하도록 생성자들을 분화시키는 것.

한계: 여러 생성자의 자원이 필요하고, 서로 다른 생성자 사이의 다양성이 늘어도 각 생성자 내부의 다양성까지 자동으로 확보되는 것은 아님.

PacGAN — "한 장은 그럴듯해도, 여러 장을 같이 보면 문제가 보이지 않을까?"

PacGAN은 **생성자는 기본적으로 유지하고, 판별자의 입력 단위**를 바꿈.

기본 GAN에서는 이미지마다 점수를 내지만, PacGAN에서는 독립적으로 뽑은 여러 이미지를 하나의 **pack, 즉 묶음**으로 만들어 점수 하나를 냄.

예를 들어 실제 데이터에는 여러 숫자가 있는데 생성자가 3만 만든다면, 실제 묶음에는 다양한 조합이 나오지만 생성 묶음에는 계속 (3, 3)만 나올 것. 그러면 판별자가 분포 차이를 알아차리기 쉬워짐.

실제 묶음을 일부러 서로 다른 숫자로 구성하는 것은 아님. 무작위로 뽑으므로 실제에서도 (3, 3)이 나올 수 있음. 문제는 **그런 조합이 얼마나 자주 나타나는가 임**

또한 "두 이미지가 비슷하면 무조건 가짜"라는 규칙을 사람이 넣는 것도 아님. **실제 묶음과 생성 묶음의 차이를 판별자가 학습**. 이미지들을 채널 방향으로 이어 붙이는 식으로 구현할 수 있다.

개선하는 부분: 샘플 단독 판단으로 드러나기 어려운 모드 누락을 더 잘 감지하는 것. 논문은 packing과 모드 붕괴의 관계를 이론적으로 분석하고 실험 개선도 보고했음.

한계: 묶음 크기에 따른 입력·자원 부담이 있고, 임의로 크게 묶는다고 무조건 좋아지는 것은 아니다

MSGAN — "입력 노이즈가 달라졌는데 왜 결과는 같을까?"

MSGAN은 특히 **조건부 GAN이 조건에만 의존하고 노이즈를 무시하는 문제**에 초점을 맞춤 같은 조건에 서로 다른 노이즈 두 개를 넣고, 다음 비율을 크게 만들도록 규제함.

$$R_{\text{MS}} = \frac{d_I(G(z_1, c), G(z_2, c))}{d_z(z_1, z_2)}$$

- 분자: 생성 이미지 두 장의 차이
- 분모: 입력 노이즈 두 개의 차이

즉, **노이즈의 차이가 출력의 차이로 이어지도록** 압력을 주는 것.

개선하는 부분: 노이즈를 무시하여 같은 조건에서 비슷한 출력만 만드는 현상.

한계: 차이를 키운다고 실제 모드를 모두 배운다는 보장은 없고, 규제가 과하면 의미 없는 변화로 차이를 늘릴 수 있음. 기존 생성 목표와의 균형이 중요

이렇듯 GAN의 한계점을 해결하려는 다양한 시도가 있었고, 근본적인 구조에 문제가 있다고 판단해서 이제 새롭게 등장한 모델이 diffusion 계열의 모델입니다.

https://jaejunyoo.blogspot.com/2017/02/unrolled-generative-adversarial-network-2.html

unrolled gan 에 대한 이해